

Treat the following questions:

I- Enumerate five algorithms used in datamining. Describe one of them by an example. **2pts**

II- How can we avoid the increasing of the volume of the data warehouse? Explain. **2pts**

III- Design the data warehouse for a wholesale furniture company. The data warehouse has to allow analyzing the company's situation at least with respect to the furniture, customers and time. **8pts**

Moreover, the company needs to analyze:

- The furniture with respect to its type (chair, table, wardrobe, cabinet. . .), category (kitchen, living room, bedroom, bathroom, office. . .) and material (wood, marble. . .)
- The customers with respect to their spatial location, by considering at least cities, regions and states

The company is interested in learning at least the quantity, income and discount of its sales.

a) Identify facts, dimensions and measures

b) For each fact:

- Produce the attribute tree and schema facts.
- Design the star or snowflake schema and write the following SQL queries:
 - Find the quantity, the total income and discount with respect to each city, type of furniture and the month
 - Find the average quantity, income and discount with respect to each country, furniture material and year
 - Determine the 5 most sold furniture during the May month

IV- You have been recruited as an expert in decision support in an exo-biology laboratory. You attend an exo-biologist who analyzes samples of things that look like plants collected on a distant planet. These exo-plants are described by four information (color, shape, size and pattern to their surface) and an important property: their edibility. **8pts**

Your mission is to find a way to decide whether an exo-plant is edible or not for humans who intend to colonize this planet.

Among 8 samples are described in the table below:

Identifier	Color	form	size	reason	class
SN-54	cyan	octagonal	small	uniform	edible
AC-951	orange	hexagonal	small	uniform	edible
ML-45	orange	octagonal	small	striped	inedible
RT-3	magenta	hexagonal	huge	striped	edible
ID-546	cyan	hexagonal	huge	striped	edible
KG-7	orange	octagonal	big	uniform	edible
XP-354	magenta	pentagonal	huge	striped	inedible
EX-76	magenta	octagonal	big	striped	inedible

- What is the entropy of the population?
- What is the attribute where the gain of information is maximal in the population?
- Construct the decision tree.
- What is the error of this tree measured on the learning game?
- Estimate the probability to classify very well a new data with a confidence of 75 %.

الإختصاص والرمز : المعلوماتية – فرع البرمجيات (1006)
المادة : أنظمة اتخاذ القرار
المستندات المسموح بها : آلة حاسبة غير مبرمجة

المعدل : (12)
المدة : ساعتان

Traiter les questions suivantes :

I- Enumérer cinq algorithmes utilisés dans la fouille de données. Décrire l'un d'eux par un exemple. **2pts**

II- Comment peut-on éviter l'augmentation du volume de l'entrepôt de données? Expliquer. **2pts**

III- Concevoir l'entrepôt de données pour une entreprise de meubles en gros. L'entrepôt de données doit permettre d'analyser la situation de l'entreprise au moins en ce qui concerne le mobilier, les clients et le temps. **8pts**

En outre, l'entreprise a besoin d'analyser:

- Les meubles à l'égard de son type (chaise, table, armoire, cabinet...), catégorie (cuisine, salon, chambre, salle de bains, bureau...) et le matériel (bois, marbre...)
- Les clients à l'égard de leur localisation spatiale, en considérant au moins les villes, les régions et les pays.

La société est intéressée à en apprendre au moins la quantité, le revenu et la réduction de ses ventes.

a) Identifier les faits, les dimensions et les mesures.

b) Pour chacun des faits:

- Produire l'attribut de l'arbre et les faits du schéma
- Modéliser le schéma de l'étoile ou le schéma en flocon et écrire les requêtes SQL suivantes:
 - Trouver la quantité, le revenu total et l'escompte à l'égard de chaque ville, le type de mobilier et le mois.
 - Trouver la quantité moyenne, les revenus et l'escompte à l'égard de chaque pays, matière de mobilier et de l'année.
 - Déterminer les 5 meubles les plus vendus au cours du mois de mai.

IV- Vous avez été recruté comme expert en aide à la décision dans un laboratoire d'exo-biologie. Vous assistez un exo-biologiste qui analyse des échantillons de choses qui ressemblent à des plantes, recueillies sur une planète lointaine. Ces exo-plantes sont décrites par quatre informations (couleur, forme, taille et motif à leur surface) et une propriété importante : leur comestibilité. **8pts**

Votre mission est de déterminer une manière de décider si une exo-plante donnée est comestible ou non pour l'espèce humaine qui envisage de coloniser cette planète.

Au nombre de 8, les échantillons sont décrits dans le tableau ci-dessous:

identificateur	couleur	forme	taille	motif	Classe
SN-54	cyan	octogonal	petit	uniforme	comestible
AC-951	orange	hexagonal	petit	uniforme	comestible
ML-45	orange	octogonal	petit	rayé	non comestible
RT-3	magenta	hexagonal	gigantesque	rayé	comestible
ID-546	cyan	hexagonal	gigantesque	rayé	comestible
KG-7	orange	octogonal	grand	uniforme	comestible
XP-354	magenta	pentagonal	gigantesque	rayé	non comestible
EX-76	magenta	octogonal	grand	rayé	non comestible

- quelle est l'entropie de la population ?
- quel est l'attribut dont le gain d'information est maximal dans la population ?
- construire l'arbre de décision.
- quelle est l'erreur de cet arbre mesurée sur le jeu d'apprentissage ?
- estimer la probabilité de bien classer une nouvelle donnée avec une confiance de 75 %.

