

المعدل : (14)
المدة : ساعتان

الإختصاص والرمز : المعلوماتية – فرع البرمجيات (1006)
المادة : أنظمة اتخاذ القرار
المستندات المسموح بها : آلة حاسبة غير مبرمجة

Treat the following questions:

I- We consider five items noted I1, I2, I3, I4 and I5 and distributed in nine transactions noted T1, T2, ..., T9 according to the table below.

Transactions	Set of Items
T1	I1 I2 I5
T2	I2 I4
T3	I2 I3
T4	I1 I2 I4
T5	I1 I3
T6	I2 I3
T7	I1 I3
T8	I1 I2 I3 I5
T9	I1 I2 I3

For a frequency threshold of 20% (an itemset is frequent if its frequency is greater than or equal to 20%), apply the Apriori algorithm to this data, detailing all the steps, to extract all the frequent itemsets. For a confidence threshold of 70%, give all association rules that can be extracted with the left member is an itemset containing two separate items.

II- The table below describes the risk for patients to have a certain disease based on their age and two symptoms called S1 and S2. The risk is evaluated according to three values **L** (low), **M** (medium) and **H** (high), the age is distributed into three classes (young, adult and senior) and the two symptoms S1 and S2 correspond to Boolean values (0 or 1).

Age	S1	S2	Risk
Young	0	1	L
Young	0	0	L
Young	1	1	H
Adult	1	0	M
Adult	0	0	L
Adult	1	1	M
Senior	1	0	H
Senior	0	0	L
Senior	0	1	M
Senior	1	1	H

Construct the decision tree allowing the prediction of the attribute Risk based on the attributes Age, S1 and S2. To do this: We will use the function "wrong-sized" defined by $I(S) = 1 - \max_k(P_k)$ (where P_k denotes the probability of the class C_k) for calculating information gain.

We will stop the construction of a tree branch if in the table associated to this branch we have at least 80% of n-tuples having the same value on the attribute risk, this value is then the leaf of the branch.

III- Given the relational schema of a cinematographic base composed of the following relations :
MOVIE (MOVIEID, TITLE, DURATION, COUNTRY, DIRECTORID, TYPE, DATE, COMPOSERID)
DIRECTOR (DIRECTORID, DNAME, DFIRSTNAME, COUNTRY)
ACTOR (ACTORID, ANAME, AFIRSTNAME, COUNTRY)
TURNING (MOVIEID, ACTORID, ROLETYPE)
COMPOSER (COMPOSERID, CNAME, CFIRSTNAME, COUNTRY)

The relation "MOVIE" describes the movies with their number, title, duration (in minutes), the country of origin of the film, the identifier of the movie's director, the type (which can take values: tragic, comic, police, romantic, intimate), the movie's release date and the music composer number.

The relation "DIRECTOR" describes the directors with their number, name, first name and the country in which they are originate.

The relation "ACTOR" describes the actors with their number, name, first name and country of their citizenship. The relation "TURNING" describes the participation of actors in movies, giving the type of played role (main role, secondary role, another role).

The relation "COMPOSER" describes the composers with their number, their name and first name and the country of their citizenship.

This database is distributed at three sites: Montreal, Toronto and Vancouver. The Montreal site stores information about movies, Toronto information on the actors and the Vancouver information about directors and composers.

We decided to build a data warehouse from this database to analyze the number of movies released per year and per country.

- Recall the different steps necessary to implement a data warehouse.
- We decide to use ROLAP technology to build this data warehouse and to use a star schema. Give the schema of the main table of this data warehouse as well as the schema of tables of dimensions.

Traiter les questions suivantes :

I- On considère cinq articles (ou items) notés I1, I2, I3, I4 et I5 et distribués dans neuf transactions notées T1, T2, ..., T9 selon le tableau ci-dessous. 7 pts

Transactions	Ensemble d'articles
T1	I1 I2 I5
T2	I2 I4
T3	I2 I3
T4	I1 I2 I4
T5	I1 I3
T6	I2 I3
T7	I1 I3
T8	I1 I2 I3 I5
T9	I1 I2 I3

Pour un seuil de fréquence de 20 % (un itemset est fréquent si sa fréquence est supérieure ou égale à 20 %), appliquer l'algorithme Apriori à ces données, en détaillant toutes les étapes, pour extraire tous les itemsets fréquents.
Pour un seuil de confiance de 70 %, donner toutes les règles d'association que l'on peut extraire et dont le membre gauche est un itemset contenant deux items distincts.

II- La table ci-dessous décrit le risque pour des patients d'avoir une certaine maladie en fonction de leur âge et de deux symptômes appelés S1 et S2. Le risque est évalué selon trois valeurs **F** (faible), **M** (moyen) et **E** (élevé), l'âge est réparti selon trois classes (jeune, adulte et senior) et les deux symptômes S1 et S2 correspondent à des valeurs booléennes (0 ou 1). 7 pts

Age	S1	S2	Risque
Jeune	0	1	F
Jeune	0	0	F
Jeune	1	1	E
Adulte	1	0	M
Adulte	0	0	F
Adulte	1	1	M
Senior	1	0	E
Senior	0	0	F
Senior	0	1	M
Senior	1	1	E

Construire l'arbre de décision permettant la prédiction de l'attribut Risque en fonction des attributs Age, S1 et S2. Pour ce faire :

On utilisera la fonction « mal-classés » définie par $I(S) = 1 - \max_k(P_k)$ (où P_k désigne la probabilité de la classe C_k) pour les calculs de gain d'information.

On arrêtera la construction d'une branche de l'arbre si dans la table associée à cette branche on a au moins 80% des n-uplets ayant la même valeur sur l'attribut Risque ; cette valeur étant alors la feuille de la branche.

III- Soit le schéma relationnel d'une base cinématographique se composant des relations suivantes: 6 pts

FILM (NOFILM, TITRE, DUREE, PAYS, NUMREAL, GENRE, DATE, NUMCOMP)

REALISATEUR (NUMREAL, NOMR, PRENOMR, PAYS)

ACTEUR (NUMA, NOMA, PRENOMA, PAYS)

TOURNAGE (NOFILM, NUMA, TYPEROLE)

COMPOSITEUR (NUMCOMP, NOMCOMP, PRENOMCOMP, PAYS)

La relation « **FILM** » décrit les films avec leur numéro, titre, durée (en minutes), le pays d'origine du film, l'identifiant du réalisateur du film, le genre (pouvant prendre les valeurs : tragique, comique, policier, romantique, intimiste), la date de sortie du film et le numéro du compositeur de la musique.

La relation « **REALISATEUR** » décrit les réalisateurs avec leur numéro, leur nom, leur prénom et le pays dont ils sont originaires.

La relation « **ACTEUR** » décrit les acteurs avec leur numéro, leur nom, leur prénom et le pays dont ils sont citoyens.

La relation « **TOURNAGE** » décrit la participation des acteurs dans les films en donnant le type du rôle joué (rôle principal, rôle secondaire, autre rôle).

La relation « **COMPOSITEUR** » décrit les compositeurs avec leur numéro, leur nom et leur prénom et le pays dont ils sont citoyens

Cette base de données est distribuée sur trois sites : Montréal, Toronto et Vancouver. Le site de Montréal conserve les informations sur les films, Toronto les informations sur les acteurs et Vancouver les informations sur les réalisateurs et les compositeurs.

Nous décidons de construire un entrepôt de données à partir de cette base de données afin d'analyser le nombre de films sortis par année et par pays.

a) Rappeler les différentes étapes nécessaires à la mise en œuvre d'un entrepôt de données.

b) Nous décidons d'utiliser la technologie ROLAP pour construire cet entrepôt de données et d'utiliser un schéma en étoile. Donner le schéma de la table centrale de cet entrepôt de données ainsi que le schéma des tables de dimensions.

