

Traiter les questions suivantes :

1. Expliquez pourquoi, pour l'intégration de sources d'informations multiples et hétérogènes, la plupart des industriels préfèrent l'approche entrepôts de données à l'approche médiateur. Décrire les situations pour lesquelles l'approche médiateur est préférable. 3 pts
2. Le tableau suivant comprend un ensemble de données d'une base de données de l'employé. Les données ont été généralisées. Par exemple, '31...35' pour l'âge, représente la tranche d'âge de 31 à 35. Pour une entrée de ligne donnée, 'compteur' représente le nombre des tuples de données ayant les valeurs département, statut, âge et salaire pour les données de cette ligne. 7 pts

département	statut	âge	salaire	compteur
Vente	débutant	31...35	46k...50K	30
Vente	supérieur	26...30	26k...30K	40
Vente	supérieur	31...35	31k...35k	40
Systèmes	supérieur	21...25	46k...50K	20
Systèmes	débutant	31...35	66k...70k	5
Systèmes	supérieur	26...30	46k...50K	3
Systèmes	débutant	41...45	66k...70k	3
Marketing	débutant	36...40	46k...50K	10
Marketing	supérieur	31...35	41k...45k	4
Secrétariat	débutant	46...50	36k...40k	4
Secrétariat	supérieur	26...30	26k...30k	6

Soit statut l'attribut étiquette (label) de la classe.

- a) Comment peut-on modifier l'algorithme de base d'arbre de décision pour prendre en considération le compteur de chaque tuple de données généralisées (c'est à dire, de chaque ligne d'entrée)?
- b) Utilisez votre algorithme pour construire un arbre de décision à partir des données fournies.
- c) Etant donné un tuple de données comportant les valeurs 'systèmes', '26 ... 30' et '46...50K' pour les attributs département, âge et salaire, respectivement, quelle sera la classification naïve bayésienne de 'statut' de ce tuple?

3. On suppose que la tâche de fouille de données est de regrouper les huit points suivants en trois groupes (avec (x;y) représente location) :
A1(2; 10); A2(2; 5); A3(8; 4); B1(5; 8); B2(7; 5); B3(6; 4); C1(1; 2); C2(4; 9):
La fonction de distance est euclidienne. Supposons initialement nous affectons A1, B1, et C1 comme le centre de chaque groupe respectivement. Utilisez l'algorithme k-moyennes (k-means algorithm) pour montrer seulement:
a) Les trois centres de groupe après la première itération d'exécution.
b) Les trois derniers groupes. 4 pts

4. On veut construire un entrepôt de données afin de stocker les informations sur les consultations médicales d'un pays. On veut notamment connaître le nombre de consultations, par rapport aux différents critères (personnes, médecins, spécialités, etc.). Ces informations sont stockées dans les relations suivantes :
PERSONNE (id, nom, tel, adresse, sexe)
MEDECIN (id, tel, adresse, spécialité)
CONSULTATION (id_med, id_pers, date, prix)
a) Proposez un schéma relationnel (un cube) qui prend en considération la date, le jour de la semaine, le mois, le trimestre et l'année.
b) A partir de ce cube, indiquez quelles opérations OLAP (roll-up, drill down, slice, dice) il faut appliquer pour obtenir les informations suivantes :
- Le coût total des consultations par médecin en 2005.
- Le nombre de consultations par jour de la semaine, par spécialité et par sexe du patient.
- Le coût des consultations par patiente pour les mois d'octobre. 6 pts

Treat the following questions:

1. Explain why, for the integration of multiple heterogeneous sources of information, most industrial prefer data warehouses approach to mediator approach. Describe the situations in which the mediator approach is preferable. 3 pts
2. The following table consists of training data from an employee database. The data have been generalized. For example, '31...35' for age, represents the age range from 31 to 35. For a given row entry, 'count' represents the number of data tuples having the values for department, status, age, and salary given in that row. 7 pts

department	status	age	salary	count
Sales	junior	31...35	46k...50K	30
Sales	senior	26...30	26k...30K	40
Sales	senior	31...35	31k...35k	40
Systems	senior	21...25	46k...50K	20
Systems	junior	31...35	66k...70k	5
Systems	senior	26...30	46k...50K	3
Systems	junior	41...45	66k...70k	3
Marketing	junior	36...40	46k...50K	10
Marketing	senior	31...35	41k...45k	4
Secretary	junior	46...50	36k...40k	4
Secretary	senior	26...30	26k...30k	6

Let *status* be the class label attribute.

- a) How would you modify the basic decision tree algorithm to take into consideration the *count* of each generalized data tuple (i.e., of each row entry)?
- b) Use your algorithm to construct a decision tree from the given data.
- c) Given a data tuple having the values 'systems', '26. . . 30', and '46...50K' for the attributes *department*, *age* and *salary*, respectively, what would a naive Bayesian classification of the *status* for the tuple be?

3. Suppose that the data mining task is to cluster the following eight points (with $(x; y)$ representing location) into three clusters. 4 pts

$A1(2; 10); A2(2; 5); A3(8; 4); B1(5; 8); B2(7; 5); B3(6; 4); C1(1; 2); C2(4; 9);$

The distance function is Euclidean distance. Suppose initially we assign $A1$, $B1$, and $C1$ as the center of each cluster, respectively. Use the *k-means* algorithm to show only:

- a) The three cluster centers after the first round of execution.
- b) The final three clusters.

4. We want to build a data warehouse to store information about medical visits of a country. We want to know in particular the number of visits in relation to various criteria (person, doctors, specialty, etc.). This information is stored in the following relationships: 6 pts

PERSON (id, name, phone, address, gender)

DOCTOR (id, phone, address, specialty)

VISIT (id_doc, id_pers, date, price)

- a) Propose a relational schema (a cube) that takes into account the date, the day of week, the month, the quarter and the year.
- b) From this cube, specify which OLAP operations (roll-up, drill down, slice, dice) must be applied to obtain the following information:
 - The total cost of visits per doctor in 2005.
 - The number of visits by day of the week, by specialty and by patient gender.
 - The visits cost per female patient for the months of October.