

Treat the following questions:**Q1 (4pts)**

Define the following terms:

- a) Data warehouse
- b) Data mart
- c) Data mining
- d) OLAP operators

Q2 (3pts)

Use the K-Means algorithm to cut the following population into 3 groups. Take 15, 37, and 58 as initial centers: 7, 10, 15, 19, 21, 34, 37, 41, 49, 53, 58, 62, 68, 72.

Q3 (7pts)

Consider the following database transactions with a minimum support = 60% and a minimum confidence = 80%.

Transaction ID	Items
T1	K, A, D, B
T2	D, A, C, E, B
T3	C, A, B, E
T4	B, A, D

- a) Find all the frequent item sets by applying the A-priori algorithm.
- b) Deduce all the association rules. For each rule, determine its support and confidence.

Q4 (6pts)

Consider the following students' grades in Biology and in English:

Student	1	2	3	4	5	6	7
Biology	3	4	6	11	16	18	19
English	7	8	9	11	13	14	15

- a) Determine the straight line obtained by applying the linear regression method. After that, predict Y if X = 13.
- b) Calculate the error rate, and then deduce the validity rate of this predictive model.

Traiter les questions suivantes :**Q1 (4 pts)**

Définir les termes suivants:

- a) Data warehouse
- b) Data mart
- c) Data mining
- d) Opérateurs OLAP

Q2 (3pts)

Utiliser l'algorithme K-Means pour découper la population suivante en 3 groupes. Prendre 15, 37 et 58 comme centres initiaux: 7, 10, 15, 19, 21, 34, 37, 41, 49, 53, 58, 62, 68, 72.

Q3 (7 pts)

Considérer les transactions de la base de données suivantes avec un support minimum = 60% et une confiance minimale = 80%.

Transaction ID	Items
T1	K, A, D, B
T2	D, A, C, E, B
T3	C, A, B, E
T4	B, A, D

- a) Trouver tous les ensembles d'items fréquents en appliquant l'algorithme A-priori.
- b) Dédire toutes les règles d'association. Pour chaque règle, déterminer son support et sa confiance.

Q4 (6 pts)

Considérer les notes suivantes des étudiants en "Biology" et en "English":

Student	1	2	3	4	5	6	7
Biology	3	4	6	11	16	18	19
English	7	8	9	11	13	14	15

- a) Déterminer la ligne droite obtenue par application de la méthode de régression linéaire. Ensuite, prédire Y si X = 13.
- b) Calculer le taux d'erreur puis déduire le taux de validité de ce modèle prédictif.