

Treat the following questions:

- 1) Describe the reasons for wish companies need to implement data mining solution.(**1.5 pts**)
- 2) Count the steps for data mining methodology.(**1.5 pts**)
- 3) Find 6 differences between on line transaction processing (OLTP) and on line analysis processing (OLAP).(**1.5 pts**)
- 4) The financial director of sportive cities in Lebanon desire creates a data-warehouse for analyzing parameters influencing on revenues. He proposes to use the following information: (**7 pts**)
 - For the spectator: spectator type (senior, junior), spectator sex (male, female).
 - For the game: game date, game time, game location, game type (Basket-ball, Football...).

He requests also to obtain two measures: count and charge. Count is a distributed number of spectators, Charge is a cost paid when a spectator watch a game in a specific location and date.

- a. Define analysis axes and their hierarchies.
 - b. Define principal measures and their aggregates.
 - c. Draw the logical model (star schema) for the data-warehouse.
 - d. Determine the number of views in MOLAP model?
- 5) Consider a sample of 6 items (A, B, C, D, E, F) distributed on 20 sale tickets as showing in the table below: (**4.5 pts**)

T1	T2	T3	T4	T5	T6	T7	T8	T9	T10	T11	T12	T13	T14	T15	T16	T17	T18	T19	T20
A	A		A		A	A			A	A	A		A	A	A	A	A		A
B		B	B	B	B	B	B	B	B		B	B	B		B	B	B	B	B
C	C	C	C	C	C	C	C	C		C	C	C	C	C	C	C	C	C	
D	D		D	D	D	D		D	D		D		D	D	D	D	D	D	D
	E				E	E	E	E	E		E	E	E	E	E			E	E
F	F	F		F	F	F	F	F	F	F	F	F			F	F	F	F	F

- a. Use Apriori algorithms to obtain the large item set using minimal support of 75%.
- b. Find the pertinent association rules using minimal confidence of 85%.
- c. Consider item B like Butter and item C like chocolate. The table below shows the distribution of B and C items across a 1000 of sale tickets. In this case test the existing of a pertinent rule between B & C items using a minimal support of 75% and a minimal confidence of 90%.

	B	Not B	Description
C	772	120	772: mean there are 772 tickets containing chocolate and butter. 120: mean there are 120 tickets containing chocolate without butter.
Not C	85	23	85: mean there are 85 sale tickets containing butter without chocolate. 23: mean there are 23 sale tickets that don't contain butter and chocolate.

- 6) Consider the data set $S=\{1, 3, 4, 6, 9, 10, 12, 27, 29\}$. In order to find 3 clusters of S; Apply the following data clustering algorithms:(**4 pts**)
 - a. K-means
 - b. Agglomeration.

Traiter les questions suivantes:

- 1) Décrire les raisons pour lesquelles les entreprises ont besoin d'implémenter la solution de fouille de données (data mining). (1.5 pts)
- 2) Compter les étapes de la méthodologie de fouille de données (datamining). (1.5 pts)
- 3) Trouver 6 différences entre le traitement transactionnel en ligne (OLTP) et l'analyse transactionnel en ligne (OLAP). (1.5 pts)
- 4) Le directeur financier des citées sportives au Liban désire créer un entrepôt de données (data-warehouse) pour analyser les paramètres qui influencent sur les revenus. Il propose à utiliser les informations suivantes: (7 pts)
 - Pour le spectateur: type de spectateur (vieux, jeune), sexe de spectateur (homme, femme).
 - Pour le jeu : date du jeu, temps du jeu, lieu du jeu, type du jeu (basket-ball, Football...).

Il demande également à obtenir deux mesures : compte et frais. Compte est le nombre distribué des spectateurs ; coût est le coût payé quand un spectateur viens de voir un jeu dans un endroit précis et une date.

 - a. Définir les axes d'analyse et leurs hiérarchies.
 - b. Définir les principales mesures et leurs agrégats.
 - c. Dessiner le modèle logique (schéma en étoile) pour le Data Warehouse.
 - d. Déterminer le nombre de vues dans le modèle MOLAP?
- 5) Examiner un échantillon de 6 éléments (A, B, C, D, E, F) répartis sur 20 billets de vente comme indiqué dans le tableau ci-dessous :

T1	T2	T3	T4	T5	T6	T7	T8	T9	T10	T11	T12	T13	T14	T15	T16	T17	T18	T19	T20
A	A		A		A	A			A	A	A		A	A	A	A	A		A
B		B	B	B	B	B	B	B	B		B	B	B		B	B	B	B	B
C	C	C	C	C	C	C	C	C		C	C	C	C	C	C	C	C	C	
D	D		D	D	D	D		D	D		D		D	D	D	D	D	D	D
	E				E	E	E	E	E		E	E	E	E	E			E	E
F	F	F		F	F	F	F	F	F	F	F	F			F	F	F	F	F

- a. Utiliser l'algorithme Apriori pour obtenir l'ensemble des éléments fréquents pour un support minimal de 75%.
- b. Trouver les règles d'associations pertinentes pour une confiance minimale de 85%.
- c. On Considère l'élément B comme Beurre et l'élément C comme chocolat. La table ci-dessous montre la distribution des éléments de B et C entre 1000 tickets de vente. Pour ce cas tester l'existence d'une règle pertinente entre les deux éléments B et C en utilisant un support minimal de 75% et une confiance minimale de 90%.

	B	Not B	Description
C	772	120	772 : veut dire qu'il y a 772 billets contenant du chocolat et du beurre. 120 : veut dire qu'il y a 120 billets contenant du chocolat sans beurre.
Not C	85	23	85 : veut dire qu'il ya 85 billets contenant du beurre sans chocolat. 23 : veut dire qu'il ya 23 billets qui ne contiennent ni du beurre et ni de chocolat.

- 6) Considérons l'ensemble de données $S = \{1,3,4,6,9,10,12,27,29\}$. Dans l'ordre de trouver 3 groupes de S ; Appliquer les algorithmes de groupage suivants: (4 pts)
 - a. K-moyen
 - b. Agglomération.

