

Treat the following questions:

Q1: (3pts)

Consider the following confusion matrix about invoice states of a company:

Invoice State		Observed			
		Paid	Delayed	Unpaid	Sum (Row)
Predicted	Paid	80		5	100
	Delayed	1	17		
	Unpaid		2	23	30
	Sum (Column)	86		30	

- Complete the above confusion matrix.
- Determine the validity of the model.
- Deduce the error rate of the model.

Q2: (3pts)

Use the K-Means algorithm to cut the following population into 3 groups. Take 12, 25, and 35 as initial centers:
24, 40, 5, 12, 21, 8, 30, 33, 25, 35, 14, 36, 27, 38.

Q3: (7pts)

Consider the following database of transactions with a minimum support = 65% and a minimum confidence = 90%.

Transaction ID	Items
T1	W, X, Y, Z
T2	Y, X, P, Q, Z
T3	P, X, Z, Q
T4	Z, X, Y

- Find all the frequent item sets by applying the A-priori algorithm.
- Deduce all the association rules. For each rule, determine its support and confidence.
- What are the valid rules?

Q4: (7pts)

The general manager of an insurance company located in many cities around the world has decided to analyze the monthly incomes of its branches. He wants to obtain the distribution of his incomes per country, city, branch, client age, client sex, and insurance policy type.

- Define the essential aggregation(s), dimensions, and their hierarchies.
- Construct the corresponding star schema.
- Transform the star schema into a snowflake schema.

Traiter les questions suivantes :**Q1: (3 pts)**

Considérons la matrice de confusion suivante à propos des états de factures d'une société:

Etat de Facture		Observé			
		Payée	En Retard	NonPayée	Somme (Ligne)
Prédit	Payée	80		5	100
	En Retard	1	17		
	NonPayée		2	23	30
	Somme (Colonne)	86		30	

- Compléter la matrice de confusion ci-dessus.
- Déterminer la validité du modèle.
- Déduire le taux d'erreur du modèle.

Q2: (3 pts)

Utiliser l'algorithme K-Means pour découper la population suivante en 3 groupes. Prendre 12, 25 et 35 comme centres initiaux: 24, 40, 5, 12, 21, 8, 30, 33, 25, 35, 14, 36, 27, 38.

Q3: (7 pts)

Considérer la base de données des transactions suivantes avec un support minimum = 65% et une confiance minimale= 90%.

Transaction ID	Items
T1	W, X, Y, Z
T2	Y, X, P, Q, Z
T3	P, X, Z, Q
T4	Z, X, Y

- Trouver tous les ensembles d'items fréquents en appliquant l'algorithme A-priori.
- Déduire toutes les règles d'association. Pour chaque règle, déterminer son support et sa confiance.
- Quelles sont les règles valides ?

Q4: (7 pts)

Le directeur général d'une société d'assurance située dans plusieurs villes du monde a décidé d'analyser le revenu mensuel de ses branches. Il veut obtenir la distribution de ses revenus par pays, ville, branche, âge du client, sexe du client ainsi que type de police d'assurance.

- Définir les agrégats essentiels, dimensions et leurs hiérarchies.
- Construire le schéma en étoile correspondant.
- Transformer le schéma en étoile en schéma en flocon.